

Clasificación temática de artículos científicos mediante análisis relacional

Aitana Valera Prados

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
aitvalpra@alum.us.es

Miguel Ángel Martínez Fernández

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
migmarfer@alum.us.es

Resumen—Este trabajo tiene como objetivo principal evaluar el impacto y la ganancia de rendimiento que aporta la integración de métricas relacionales basadas en topología de redes combinadas con las técnicas tradicionales de procesamiento de texto para la tarea de clasificación automática de artículos científicos. Se ha empleado el conjunto de datos *Cora*, que fue construido a partir de un sistema de búsqueda de papers científicos que, además de facilitar búsquedas por palabras clave, organiza los artículos en una jerarquía temática de ciencias de la computación y recoge los enlaces de citación entre ellos [2]. Se ha modelado la estructura de citas bibliográficas mediante un grafo dirigido y no dirigido, extrayendo características estructurales avanzadas como centralidades de grado, intermediación, cercanía, *PageRank*, coeficientes de *clustering* y pertenencia a comunidades.

Los resultados obtenidos muestran que el árbol de decisión es el modelo con mejor rendimiento en todas las configuraciones evaluadas, especialmente al combinar métricas relacionales con representación *bag-of-words*. Destaca que el uso exclusivo de métricas relacionales obtiene un rendimiento cercano al de la combinación completa, lo que evidencia que la estructura de la red de citas aporta por sí sola un contexto semántico implícito relevante para la clasificación temática, sin necesidad de analizar el contenido textual de los artículos.

Palabras clave—Inteligencia Artificial, Minería de Grafos, Clasificación de Texto, Redes de Citas, Dataset Cora, Aprendizaje Supervisado, Análisis Relacional, Validación Cruzada, Hiperparámetros, F1-macro, Bag-of-Words, Centralidad, PageRank, Clustering, Detección de Comunidades.

I. INTRODUCCIÓN

El volumen de publicaciones científicas ha crecido de manera exponencial en las últimas décadas, dificultando la organización y clasificación manual de artículos por área temática. Tradicionalmente, el procesamiento de lenguaje natural (PLN) ha abordado este reto analizando los resúmenes o textos completos mediante vectores de frecuencias de términos. Sin embargo, este enfoque estático ignora una de las señales de información más ricas presentes en la literatura académica: el hipervínculo natural establecido mediante la red de referencias cruzadas y citas bibliográficas [1].

El presente proyecto aborda directamente la clasificación multiclase de publicaciones científicas combinando dos dimensiones de características independientes. Por un lado, los atributos textuales binarios que capturan la presencia o ausencia de un vocabulario controlado; por otro lado, variables numéricas continuas y discretas que formalizan la importancia estructural del documento en su red de citación. Para ello, se emplea

el clásico conjunto de datos analítico *Cora Dataset*, el cual agrupa miles de publicaciones de ciencias de la computación dentro de siete categorías temáticas bien delimitadas [2]. La solución se enfoca en someter los conjuntos de datos combinados y aislados a procesos exhaustivos de optimización de hiperparámetros mediante validación cruzada.

El resto del documento se organiza de la siguiente manera: la Sección II describe los fundamentos teóricos empleados; la Sección III detalla la metodología seguida; la Sección IV presenta los resultados obtenidos; finalmente, la Sección V recoge las conclusiones del trabajo.

II. PRELIMINARES

En esta sección se describen los fundamentos teóricos sobre los que se sustenta el trabajo, incluyendo los conceptos básicos de teoría de grafos empleados y los algoritmos de aprendizaje automático utilizados.

A. Descripción del conjunto de datos

El dataset Cora [2] está compuesto por dos ficheros:

- **cora.content:** contiene una tabla con el identificador de cada paper, 1433 atributos binarios que indican la presencia o ausencia de cada palabra del vocabulario en el paper, y la clase temática a la que pertenece. El vocabulario fue construido eliminando las palabras con frecuencia de documento inferior a 10 y los conectores textuales (*stopwords*) [2].
- **cora.cites:** contiene una tabla con el id del paper citado y el id del paper que lo cita.

La TABLA I resume las principales características del dataset Cora utilizado en este trabajo. El conjunto de datos contiene un total de 2708 publicaciones científicas conectadas mediante 5429 enlaces de citación.

TABLA I
CARACTERÍSTICAS PRINCIPALES DEL DATASET CORA

Propiedad	Valor
Número de papers	2708
Número de enlaces	5429
Número de clases	7
Tamaño del vocabulario	1433
Tipo de relaciones	Citaciones
Representación textual	Bag-of-Words binario

A partir de estos datos se modela el conjunto de papers como un grafo dirigido $G_d = (V, E_d)$, donde cada vértice representa un paper y cada arista dirigida una cita bibliográfica, y su correspondiente versión no dirigida $G = (V, E)$.

El grafo dirigido $G_d = (V, E_d)$ se emplea para el cálculo de todas las métricas relacionales, ya que la orientación de las citas aporta información relevante sobre el flujo de influencia entre publicaciones. La única excepción es la detección de comunidades, para la cual se utiliza el grafo no dirigido $G = (V, E)$, dado que el algoritmo de modularidad codiciosa empleado requiere un grafo no dirigido y la pertenencia a una comunidad no depende de la dirección de las citas sino de la densidad de conexiones entre los nodos.

B. Métricas relacionales

- **Métricas relacionales de centralidad:** Permiten cuantificar la relevancia de un nodo basado en sus enlaces. Se calculan las centralidades de grado entrante y saliente, la intermediación (*betweenness*), definida en la ecuación 1,

$$C_B(u) = \sum_{s \neq u \neq t} \frac{\sigma_{st}(u)}{\sigma_{st}} \quad (1)$$

donde σ_{st} es el número total de caminos más cortos entre los nodos s y t , y $\sigma_{st}(u)$ es el número de dichos caminos que pasan por u . La cercanía (*closeness*), definida en la ecuación 2,

$$C_C(u) = \frac{|V_u| - 1}{|V| - 1} \cdot \frac{|V_u| - 1}{\sum_{v \in V_u} d(v, u)} \quad (2)$$

donde $|V_u|$ es el número de nodos alcanzables desde u , $|V|$ es el total de nodos del grafo y $d(v, u)$ es la distancia más corta entre los nodos v y u .

Se calcula el prestigio a través del algoritmo *PageRank*, cuya probabilidad de transición e importancia estructural se define formalmente como

$$PR(u) = \frac{1 - \alpha}{|V|} + \alpha \sum_{v \in B_u} \frac{PR(v)}{L(v)} \quad (3)$$

donde α representa el factor de amortiguación (fijado en 0.85), B_u es el conjunto de nodos que apuntan a u , y $L(v)$ es el grado de salida del nodo v . Asimismo, el grado de cohesión vecinal se cuantifica mediante el coeficiente de *clustering* local

$$C(u) = \frac{2 |\{(v, w) \in E : v, w \in N_u\}|}{k_u(k_u - 1)} \quad (4)$$

donde N_u representa el conjunto de vecinos inmediatos del nodo u y k_u denota su grado total, midiendo la proporción de aristas existentes entre sus vecinos respecto al total de conexiones posibles.

- **Detección de comunidades:** Agrupamiento no supervisado basado en la densidad de conexiones internas, empleando la optimización de la modularidad codiciosa (*Greedy Modularity*).

C. Algoritmos de aprendizaje automático

Los modelos de clasificación supervisada empleados en este trabajo han sido implementados mediante la biblioteca *scikit-learn* de Python. Para cada modelo se ha realizado una búsqueda en rejilla (*GridSearchCV*) con validación cruzada de 10 pliegues para seleccionar los hiperparámetros óptimos, usando el F1 macro como métrica de evaluación.

La búsqueda en rejilla evalúa de forma exhaustiva todas las combinaciones posibles de un conjunto de valores candidatos para cada hiperparámetro. Para estimar el rendimiento de cada combinación, se emplea validación cruzada de k pliegues: el conjunto de entrenamiento se divide en k subconjuntos de igual tamaño, el modelo se entrena sobre $k - 1$ de ellos y se evalúa sobre el restante, rotando la partición de validación k veces. La puntuación final de cada combinación es la media de las k evaluaciones. En este trabajo se fija $k = 10$.

Como métrica de evaluación se emplea el F1-macro, definido como la media aritmética del F1 de cada clase:

$$F1\text{-macro} = \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} \frac{2 \cdot P_c \cdot R_c}{P_c + R_c} \quad (5)$$

donde $\mathcal{C}$ es el conjunto de clases, P_c y R_c son la precisión y la exhaustividad de la clase c , respectivamente. Al promediar sin ponderar por el tamaño de cada clase, el F1-macro penaliza por igual los errores en clases minoritarias y mayoritarias, lo que lo hace especialmente adecuado para conjuntos de datos como Cora, donde las siete clases no están representadas en igual proporción.

- **Árbol de decisión (CART):** modelo que aprende reglas de clasificación jerárquicas particionando recursivamente el espacio de *features*. Los hiperparámetros optimizados han sido la profundidad máxima del árbol (*max_depth*), con valores entre 3 y 10, y el número mínimo de ejemplos en un nodo hoja (*min_samples_leaf*), con valores 5, 10 y 15.
- **k vecinos más cercanos (k NN):** clasifica cada ejemplo según la clase mayoritaria entre sus k ejemplos más cercanos en el espacio de *features*. Requiere normalización previa de los atributos mediante *MinMaxScaler* para evitar que ninguna *feature* domine sobre las demás. Los hiperparámetros optimizados han sido el número de vecinos (*n_neighbors*) y la métrica de distancia (*metric*).
- **Naive Bayes categórico:** modelo probabilístico que asume independencia entre los atributos dado el valor de la clase. Requiere discretización previa de los atributos continuos mediante *KBinsDiscretizer*. Los hiperparámetros optimizados han sido el número de intervalos de discretización (*n_bins*) y el parámetro de suavizado de Laplace (*alpha*).

Para evitar la fuga de datos (*data leakage*) durante la búsqueda en rejilla, los modelos que requieren preprocesamiento previo, concretamente k NN (normalización mediante *MinMaxScaler*) y Naive Bayes (discretización mediante *KBinsDiscretizer*), han sido encapsulados en una tubería (*Pipeline*), de forma que el preprocesador se ajusta

únicamente sobre los datos de entrenamiento de cada pliegue y se aplica posteriormente sobre los datos de validación.

D. Trabajo Relacionado

El dataset Cora constituye un banco de pruebas estándar en el campo del aprendizaje automático sobre grafos [2]. Los enfoques iniciales se basaban exclusivamente en la representación textual de los artículos mediante *bag-of-words*, sin explotar la estructura de la red de citas. Posteriormente se desarrollaron métodos de aprendizaje de representaciones latentes en baja dimensión como *Node2Vec* [3] y las Redes Neuronales de Grafos (GNN) [4].

Estos métodos han demostrado obtener resultados superiores en tareas de clasificación de nodos y predicción de enlaces. Sin embargo, presentan ciertas limitaciones prácticas. En primer lugar, los *embeddings* generados por técnicas como *Node2Vec* poseen una interpretabilidad reducida, ya que cada dimensión carece de significado semántico explícito. Por otro lado, las GNN requieren una mayor complejidad computacional y un proceso de entrenamiento más costoso, especialmente en grafos de gran tamaño.

A diferencia de estos enfoques, en este trabajo se opta por la construcción manual de *features* relacionales explícitas. Este enfoque, aunque menos preciso, ofrece una mayor interpretabilidad al permitir analizar directamente la contribución de cada métrica a la clasificación, siendo además más adecuado para datasets de tamaño moderado como Cora.

III. METODOLOGÍA

La Fig. 1 resume el flujo completo seguido en el proceso experimental, desde la construcción del grafo de citas hasta la evaluación final de los modelos de clasificación.




Fig. 1. Pipeline general del proceso experimental.

En primer lugar, partiendo de los dos archivos *cora.content* y *cora.cites*, se construye el grafo dirigido de citas bibliográficas $G_d = (V, E_d)$ con la librería *networkx*. Dado que el algoritmo de detección

de comunidades requiere un grafo no dirigido, se construye también su correspondiente versión no dirigida $G = (V, E)$. Posteriormente se calculan los atributos centralidad-grado-in, centralidad-grado-out, centralidad-intermediacion, centralidad-cercania, pagerank, clustering y comunidad como candidatos a métricas relacionales que se incluirán en el modelo de clasificación.

Se determina si una métrica es útil mediante un análisis de comprobación de las métricas relacionales, que incluye los siguientes pasos:

- 1) *Distribución de métricas por clase*: Para que una métrica sea útil como predictor, los papers de distintas clases deben presentar distribuciones estadísticamente distintas en dicha métrica. Las figuras 2 y 3 muestran los diagramas de caja (*boxplots*) de cada métrica desglosados por clase temática (etiquetas 0–6).

En la Fig. 2 se observa que tanto *centralidad_grado_in* como *centralidad_intermediacion* y *centralidad_cercania* presentan medianas prácticamente nulas en todas las clases, con una dispersión que se concentra en valores atípicos aislados. Este patrón indica que la gran mayoría de los nodos del grafo de citas tienen valores muy bajos en estas métricas independientemente de su clase temática, lo que propone una escasa capacidad discriminativa. Por el contrario, *centralidad_grado_out* muestra una distribución más uniforme entre clases, con medianas similares pero rangos más amplios y diferencias apreciables en la clase 4, cuya caja presenta mayor extensión superior, sugiriendo que los papers de esa categoría tienden a citar un mayor número de referencias.

En la Fig. 3, *pagerank* presenta un comportamiento similar al del grado entrante: medianas cercanas a cero y *outliers* dispersos sin patrón claro por clase, lo que refleja que la influencia global calculada por *PageRank* no está correlacionada con la temática del paper. La métrica *clustering* muestra medianas bajas pero con mayor variabilidad entre clases. Finalmente, *comunidad* es la métrica con mayor poder discriminativo visual: los rangos y las medianas difieren claramente entre clases, siendo la clase 2 la que presenta la mayor dispersión y los valores más elevados.

- 2) *Test de Kruskal-Wallis TABLA II*: La inspección visual de los *boxplots* permite una primera visión, pero no es suficiente para determinar si las diferencias observadas entre clases son estadísticamente significativas. Para formalizarlo se aplica el test de Kruskal-Wallis [5]. Este test no paramétrico evalúa si las muestras de varias clases provienen de la misma distribución, sin asumir normalidad ni homogeneidad de varianzas. El resultado produce un estadístico de prueba (llamado H) junto con




Fig. 2. Distribución de métricas por clase: centralidad de grado entrante, saliente, de intermediación y de cercanía.




Fig. 3. Distribución de métricas por clase: pagerank, clustering y comunidad.

un valor p (p-value). Un valor $p < 0.05$ determina que existen diferencias estadísticamente significativas entre, al menos, un par de grupos, lo que indica que la métrica tiene capacidad discriminativa respecto a la clase temática y por tanto es útil como *feature* predictiva. Por el contrario, las métricas con $p \geq 0.05$ no presentan diferencias significativas entre clases, lo que sugiere que sus valores se distribuyen de forma similar independientemente de la clase del paper. En consecuencia, se descartan *centralidad_grado_in* ($p = 0.3751$), *centralidad_intermediacion* ($p = 0.1293$), *centralidad_cercania* ($p = 0.1006$) y *pagerank* ($p = 0.3284$), ya que incluirlas no aportaría información discriminativa al modelo y podría introducir ruido en el proceso de aprendizaje.

TABLA II
TEST DE KRUSKAL-WALLIS PARA MÉTRICAS PRE-SELECCIONADAS

Métrica Evaluada	H	p-value	¿Pasa el test?
<i>centralidad_grado_in</i>	6.45	0.3751	No
<i>centralidad_grado_out</i>	38.92	0.0000	Sí
<i>centralidad_intermediacion</i>	9.89	0.1293	No
<i>centralidad_cercania</i>	10.63	0.1006	No
<i>pagerank</i>	6.92	0.3284	No
<i>clustering</i>	27.26	0.0001	Sí
<i>comunidad</i>	978.56	0.0000	Sí

3) *Correlación entre métricas* Fig. 4: Una vez descartadas las métricas sin capacidad discriminativa, se analiza la redundancia entre las tres métricas seleccionadas para evitar que el clasificador reciba información duplicada. Si la correlación entre dos atributos es muy alta (su valor absoluto es cercano a uno), puede considerarse que ambas métricas están capturando información similar o redundante. En estos casos, es posible eliminar una de ellas para evitar redundancia en el análisis.

Para estudiar esta relación se ha utilizado la correlación de Spearman [6]. La correlación de Spearman se basa en los rangos de los valores en lugar de los valores originales, lo que permite medir relaciones monótonas entre variables, incluso cuando estas no siguen una relación lineal.

La matriz de correlación se representa como un mapa de calor en la Fig. 4. Las tres métricas que superaron el test de Kruskal-Wallis (*centralidad_grado_out*, *clustering* y *comunidad*) presentan correlaciones bajas entre sí, lo que confirma que cada métrica aporta una perspectiva distinta sobre la posición del paper en la red de citas: cuánto cita a otros, cómo de interconectados están sus vecinos, y a qué grupo temático implícito pertenece según la estructura de la red.

El conjunto de datos se divide en un 80% para entrenamiento y un 20% para prueba, resultando en 2166 muestras de entrenamiento y 542 muestras de prueba. Esta misma partición, fijada con *random_state=42*, se reutiliza en los tres experimentos para garantizar que los resultados sean directamente comparables.

Con el fin de evaluar la contribución independiente y combinada de cada tipo de información, se definen tres conjuntos de *features*:

- **Métricas relacionales + BoW:** combinación de las tres métricas seleccionadas (*centralidad_grado_out*, *clustering*, *comunidad*) con los 1433 atributos binarios de la bolsa de palabras.
- **Solo BoW:** únicamente los 1433 atributos textuales, sin ninguna información relacional.
- **Solo métricas relacionales:** únicamente las tres métricas relacionales, sin ninguna información textual.

Sobre cada uno de estos conjuntos se entrena y optimiza cada clasificador mediante *GridSearchCV* con validación cruzada de 10 pliegues y F1-macro como métrica de evalu-




Fig. 4. Correlación entre métricas relacionales.

ación. Los espacios de búsqueda de hiperparámetros son los mismos en los tres experimentos para cada clasificador, de modo que las diferencias en los hiperparámetros óptimos resultantes reflejan la adaptación de cada modelo a la naturaleza del conjunto de *features* empleado.

IV. RESULTADOS

La TABLA III recoge los valores de F1-macro obtenidos sobre el conjunto de prueba para cada combinación de modelo y conjunto de *features*. Los hiperparámetros óptimos seleccionados por la búsqueda en rejilla para cada experimento se detallan en la TABLA IV.

TABLA III
F1-MACRO EN EL CONJUNTO DE PRUEBA PARA CADA MODELO Y CONJUNTO DE FEATURES

Modelo	Relacional + BoW	Solo BoW	Solo Relacional
CART	0,720	0,572	0,698
kNN	0,414	0,413	0,514
Naive Bayes	0,388	0,066	0,388

El árbol de decisión CART es el modelo con mejor rendimiento en los tres conjuntos evaluados. En la configuración completa (Relacional + BoW) alcanza un F1-macro de 0,720, lo que supone una mejora de 0,148 puntos respecto al uso exclusivo de BoW y de tan solo 0,022 puntos respecto al uso exclusivo de métricas relacionales. Este resultado es especialmente relevante desde el punto de vista interpretativo, ya que indica que la información relacional derivada del grafo de citas aporta una señal predictiva de gran calidad, incluso en ausencia de información textual.

En particular, el hecho de que un conjunto reducido de únicamente tres *features* topológicas consiga un rendimiento

TABLA IV
HIPERPARÁMETROS ÓPTIMOS POR MODELO Y CONJUNTO DE FEATURES

Modelo	Conjunto	Hiperparámetros óptimos
CART	Relacional + BoW	max_depth=9, min_samples_leaf=5
	Solo BoW	max_depth=10, min_samples_leaf=5
	Solo Relacional	max_depth=7, min_samples_leaf=10
kNN	Relacional + BoW	n_neighbors=1, metric=manhattan
	Solo BoW	n_neighbors=1, metric=manhattan
	Solo Relacional	n_neighbors=1, metric=manhattan
Naive Bayes	Relacional + BoW	n_bins=6, alpha=4
	Solo BoW	n_bins=3, alpha=1
	Solo Relacional	n_bins=6, alpha=4

tan próximo al obtenido con 1433 atributos basados en bolsa de palabras sugiere que la estructura de la red de citas no solo complementa la información textual, sino que en cierta medida la resume. Esto se explica por la naturaleza del propio proceso de citación, en el que los artículos tienden a enlazar trabajos de su misma área temática, generando comunidades densamente conectadas que reflejan relaciones semánticas implícitas.

El kNN obtiene su mejor rendimiento utilizando exclusivamente métricas relacionales (0,514), superando incluso la configuración que combina ambas fuentes de información (0,414). Este comportamiento puede explicarse por la naturaleza del espacio de alta dimensionalidad inducido por la representación BoW. Al incorporar 1433 atributos binarios adicionales, el espacio de características se vuelve disperso, reduciendo la capacidad del modelo para identificar vecinos verdaderamente relevantes al dejar de ser informativas las distancias.

Este efecto se ve reforzado por el hecho de que el valor óptimo de $k = 1$ se mantiene constante en los tres experimentos, lo que sugiere que el modelo no logra capturar estructuras locales robustas en el espacio de características y tiende a depender de ejemplos individuales muy cercanos, mostrando un comportamiento cercano a la memorización.

Naive Bayes presenta el comportamiento más inestable de los modelos evaluados. Su rendimiento con solo BoW (0,066) es prácticamente equivalente a una clasificación aleatoria en un problema de siete clases.

En contraste, cuando se emplean únicamente métricas relacionales, el rendimiento aumenta hasta 0,388, lo que sugiere que la discretización de variables continuas mediante KBinsDiscretizer permite al modelo capturar parcialmente patrones estructurales más estables. Sin embargo, la combinación de ambas fuentes de información no produce una mejora significativa, lo que refuerza la idea de que Naive Bayes es especialmente sensible a la heterogeneidad y escala de los atributos de entrada.

V. CONCLUSIONES

Este trabajo ha evaluado el impacto de integrar métricas relacionales derivadas de la red de citas bibliográficas en la clasificación temática de artículos científicos del dataset Cora. Los resultados muestran que el árbol de decisión CART es el modelo más adecuado para este problema, alcanzando un F1-macro de 0,720 en la configuración completa. El hallazgo más relevante es que el uso exclusivo de las tres métricas topológicas seleccionadas (`centralidad_grado_out`, `clustering` y `comunidad`) obtiene un F1-macro de 0,698, apenas 0,022 puntos por debajo de la combinación completa y 0,126 puntos por encima del uso exclusivo de BoW. Esto evidencia que la estructura de la red de citas encierra por sí sola una señal temática implícita de alta densidad informativa, sin necesidad de analizar el contenido textual de los artículos.

No todos los modelos se benefician por igual de la combinación de ambas fuentes de información. El kNN ve degradado su rendimiento al incorporar las 1433 dimensiones de BoW, mientras que Naive Bayes colapsa con BoW en solitario por la inadecuación de la discretización sobre atributos binarios. Estos resultados subrayan que la elección del clasificador es tan determinante como la selección de *features*.

Como líneas de trabajo futuro se plantea la incorporación de esquemas de ponderación TF-IDF en lugar de la representación binaria actual, la aplicación de técnicas de escalado a las métricas estructurales para mejorar el rendimiento de modelos sensibles a la escala como kNN, y la exploración de modelos de ensamblado como Random Forest o XGBoost, que podrían explotar mejor la heterogeneidad entre los atributos textuales y topológicos.

REFERENCIAS

- [1] C. Yang, Z. Liu, D. Zhao, M. Sun, y E. Y. Chang, "Network Representation Learning with Rich Text Information," en *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI)*, 2015, pp. 2111–2117.
- [2] Andrew McCallum, "Cora," *IEEE Dataport*, March 11, 2024, doi: 10.21227/jsg4-wp31.
- [3] A. Grover and J. Leskovec, "node2vec: Scalable feature learning for networks," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2016.
- [4] L. Wu, P. Cui, J. Pei, and L. Zhao, *Graph Neural Networks: Foundations, Frontiers, and Applications*. Springer Singapore, 2022.
- [5] W. H. Kruskal and W. A. Wallis, "Use of ranks in one-criterion variance analysis," *Journal of the American Statistical Association*, vol. 47, no. 260, pp. 583–621, 1952.
- [6] C. Spearman, "The proof and measurement of association between two things," *The American Journal of Psychology*, vol. 15, no. 1, pp. 72–101, 1904.